Escola Nacional de Ciências Estatísticas (ENCE)

Disciplina: Modelo Linear

Relatório de Regressão Linear Múltipla
Aplicação em Dados de Consumo de Combustível

Alunos: Daniel e Richard

Professor: Daniel Takata

Julho de 2025

Relatório de Regressão Linear Múltipla Dados: dados4.xlsx

1. Introdução

Este relatório apresenta a modelagem do consumo de combustível (variável Y) de automóveis a partir de variáveis explicativas numéricas e categóricas. Foram aplicadas técnicas de regressão linear múltipla, diagnósticos de pressupostos, tratamento de observações influentes e seleção de variáveis via método stepwise

As variáveis são as seguintes:

Y=Economia de combustivel em milhas por galão

X1=Carro ou caminhão

X3=Deslocamento em pés cúbicos

X4=Código de transmissão

X5=Peso equivalente de teste

X6=Razão de compressão

X7=Razão de eixo

X8=Razão vmvv(velocidade do motor versus velocidade do veículo)

2. Preparação dos Dados

Os dados foram importados do arquivo dados4.xlsx. As variáveis categóricas X1 (tipo de tração) e X4 (tipo de motor/transmissão) foram transformadas em variáveis dummies, resultando nas colunas V1, V2 e V3. Todas as demais variáveis já estavam em formato numérico. A variável V1 é 1 se X1 é carro(C) e 0 se X1 é caminhão(T). As variáveis V2 e V3 seguem o seguinte critério: Se X4 tem Código de transmissão L5 V2=0 e V3=1, se X4

tem Código de transmissão L4 V2=0 e V3=0, por fim, se X4 tem Código de transmissão M6, V2=1 e V3=0 Como mostra o quadro a seguir

X1	V1
Carro(C)	0
Caminhão(T)	1

X4	V2	V3
L5	0	1
L4	0	0
M5	1	0

3. Análise Exploratória

Para as variáveis categóricas foram usados gráficos Boxplots e para as numéricas foram usados gráficos de dispersão.

Gráficos Boxplots (variáveis categóricas vs Y)

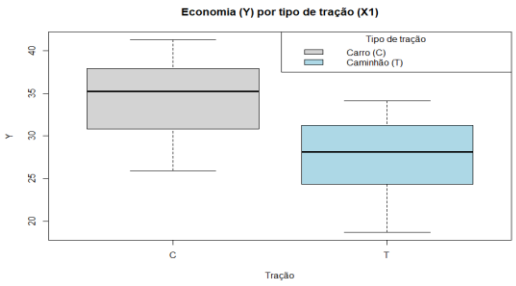

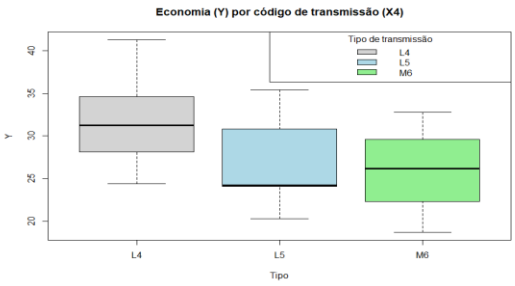

É possível notar que carros (C), em geral, são mais econômicos que Caminhões (T), além disso, há uma aparente presença de outlier no conjunto de dados de caminhões (T). Agora, ao analisarmos a economia pelo código de transmissão, L4 é o mais econômico e o L5 apresentar a pior economia de combustível. Também é possível enxergar a presença de outlier em L4.

Gráficos de dispersão (variáveis numéricas vs Y):

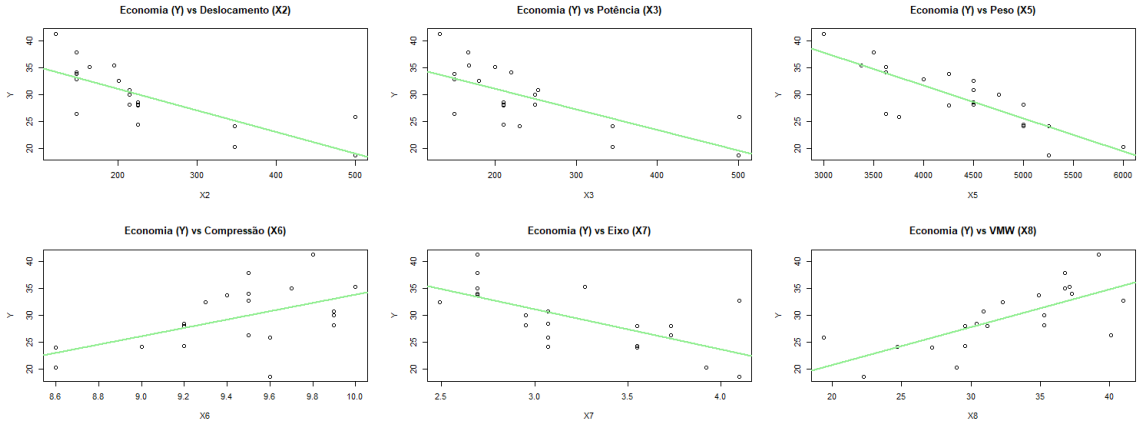

Analisando os gráficos, é possível suspeitar da presença de outliers em X2, X3 e X6. Para as outras variáveis, não há como suspeitar com 100% de clareza que há outliers apenas pela visualização dos gráficos de dispersões.

4. Analisando o Modelo Inicial

A variável X1 e X4 estão sendo representadas pelas variáveis dummies.

Modelo inicial:
Y ~ X2 + X3 + X5 + X6 + X7 + X8 + V1 + V2 + V3

Diagnóstico inicial

O modelo inicial apresentou um R^2 ajustado igual a 0.8617, indicando que a economia de combustível (Variável resposta) está sendo bem explicada pelas variáveis explicativas, no entanto, nenhuma das variáveis explicativas apresentaram significância estatística a 5%, indicando uma colinearidade ou presença de outliers.

Resultado dos testes

• Normalidade dos resíduos (Teste de Shapiro) – P-VALOR = 0.2008, não há evidência contra a normalidade dos resíduos ao nível de 5%
• Heterocedasticidade (Breusch–Pagan e White) – P-VALORES = 0.02351 (BPTEST) e 0.6365 (WHITE_TEST), o teste de Breusch-Pagan apresentou p-valor inferior a 0,05, indicando a presença de heterocedasticidade nos resíduos. Por outro lado, o teste de White, mais geral, não detectou evidência significativa de 5%, sugerindo que a heterocedasticidade esteja seguindo uma estrutura linear simples.

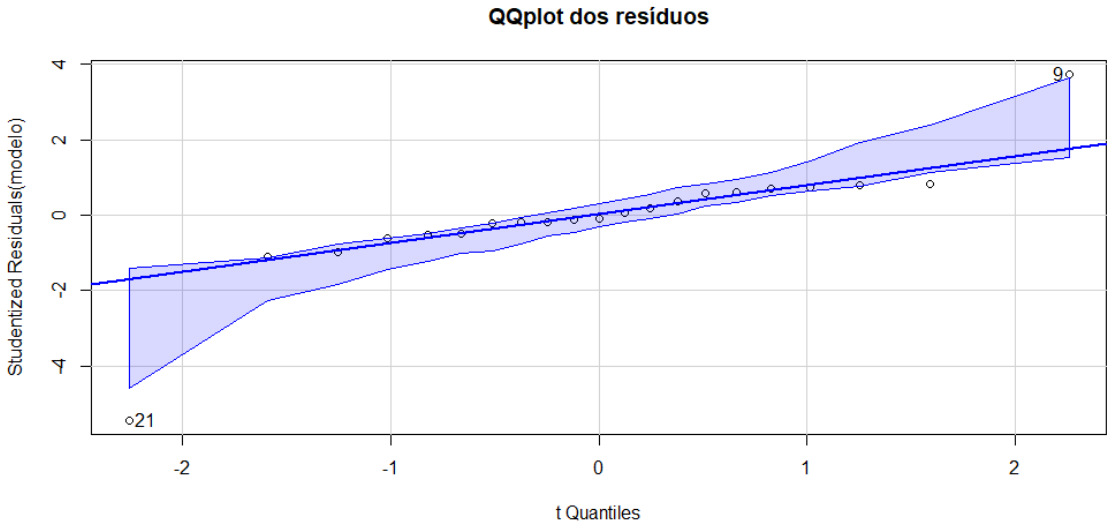

Analise da multicolinearidade

Os VIFs das variaveis são as seguintes:

X2	X3	X5	X6	X7	X8	V1	V2	V3
38.632	14.253	5.7501	2.2642	2.7071	13.3552	3.9269	4.2881	2.5475

• Multicolinearidade (VIF) – A variável X2 apresentou um VIF de 38.6322, uma clara evidência de multicolinearidade, sendo necessária à sua retirada do modelo.

5. Analise do Modelo sem X2

Após remover X2 devido à alta multicolinearidade, o modelo passou a ser:

Y ~ X3 + X5 + X6 + X7 + X8 + V1 + V2 + V3

Diagnóstico inicial

O modelo sem X2 apresentou um R^2 ajustado igual a 0.873, indicando houve um leve aumento na explicação da economia de combustível (Variável resposta) através das variáveis explicativas. Além disso, as variáveis explicativas apresentaram aumento de significância estatística após a remoção de X2 ao nível de 5%, mais especificamente, X5 e X8.

Resultado dos testes

• Normalidade dos resíduos (Teste de Shapiro) – P-VALOR = 0.1761, continua não havendo evidência contra a normalidade dos resíduos ao nível de 5%

• Heterocedasticidade (Breusch–Pagan e White) – P-VALORES = 0.01466 (BPTEST) e 0.6513 (WHITE_TEST), tendo a mesma interpretação do modelo com a variável X2.

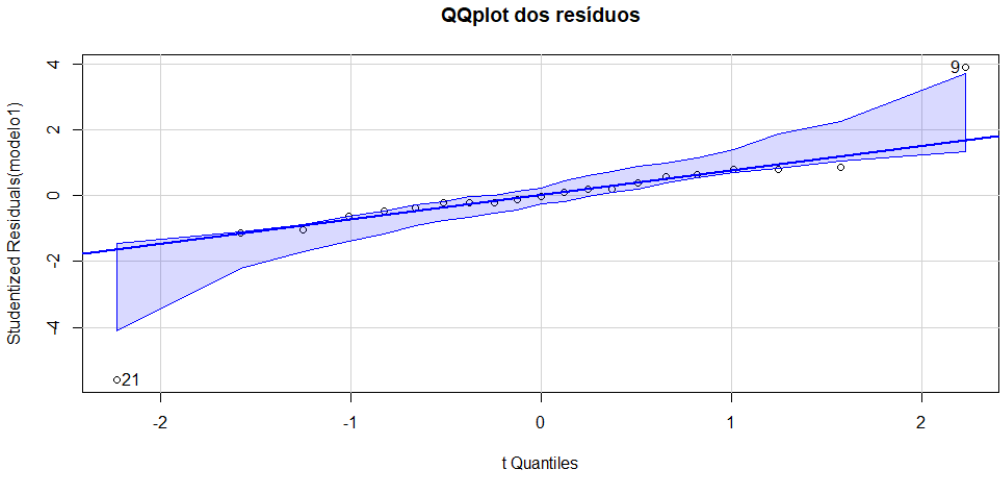

Analise da multicolinearidade

Os VIFs das variaveis são as seguintes:

X3	X5	X6	X7	X8	V1	V2	V3
5.8118	5.7468	2.2640	2.6988	4.5126	3.8652	3.4387	1.9621

• Multicolinearidade (VIF) – As variáveis X3 e X5 apresentaram VIFs acima de 5, será necessário observar essas variáveis em futuros modelos. Já X8 teve seu VIF bastante reduzido após a retirada de X2, demostrando uma alta colinearidade entre as duas.

Analise sobre a presença de outliers

Os 8 maiores DFFITs das observações em ordem decrescente foram

21	9	17	5	15	16	2	6
5.3948	4.1453	0.7255	0.7048	0.6975	0.6018	0.5614	0.5416

Ao usarmos a formula do limite do DFFIT encontramos um valor de 1.3093, as observações 21 e 19 apresentaram os respectivos DFFITS, 5.3948 e 4.1453, por isso, serão retiradas do modelo.

6. Analise do Modelo sem Observações Influentes

Observações 9 e 21 foram removidas, resultando em novo conjunto de dados. O modelo foi novamente ajustado com as mesmas variáveis.

Y ~ X3 + X5 + X6 + X7 + X8 + V1 + V2 + V3

Diagnóstico inicial

Com a retirada de desses outliers o R^2 ajustado subiu para 0.9643, mostrando que essa mudança tornou o modelo mais eficaz em explicar a variável Y. Além disso, X7 se tornou uma variável explicativa com significância, se unindo as variáveis X5 e X8 que já eram significantes com os outliers presentes.

Resultado dos testes

• Normalidade dos resíduos (Teste de Shapiro) – P-VALOR = 0.2999, continua não havendo

evidência contra a normalidade dos resíduos ao nível de 5%
• Heterocedasticidade (Breusch–Pagan e White) – P-VALORES = 0.7723 (BPTEST) e 0.60854 (WHITE_TEST). Após a remoção dos outliers, não houve mais evidências de heterocedasticidade nos resíduos pelo teste de Breusch-Pagan, sugerindo que os pontos influentes estavam contribuindo para a violação dessa suposição do modelo de regressão.

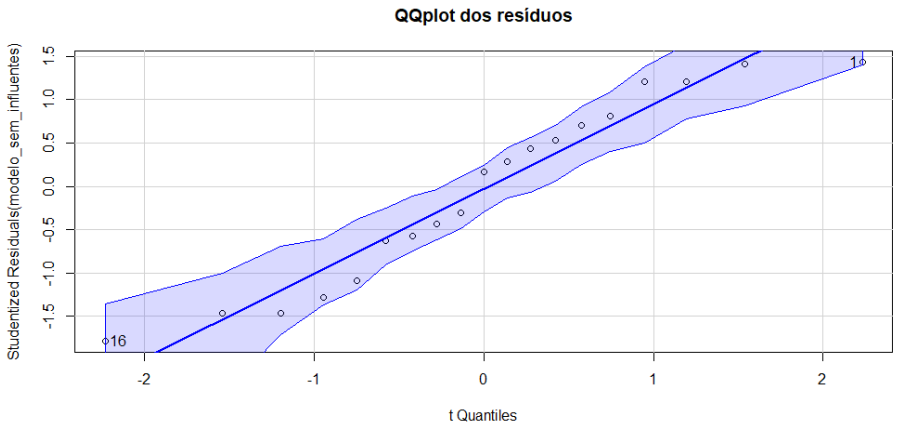

7. Seleção de Variáveis (Stepwise)

Como já dito anteriormente, após a retirada de X2 e dos outliers, as variáveis X5, X7 e X8 com os respectivos p-valores, 0.011482, 0.004145 e 0.004777, tornaram-se significativas ao nível de 5%. Nesse modelo foi utilizado o modelo stepwise bidirecional.

O passo a passo será ilustrado a seguir:

Passos	Variável incluída	Modelo atual	R^2
1	X5	Y ~ X5	0.750
2	X8	Y ~ X5 + X7	0.936
3	X7	Y ~ X5 + X7 + X8	0.966

Na primeira etapa, a variável X5 foi incluída, resultando em um R^2 simples de 0,750. Em seguida, a variável X8 foi adicionada ao modelo, elevando o R^2 para 0,936. Por fim, a

inclusão de X7 aumentou o R^2 para 0,966. Nenhuma outra variável atendeu ao critério para ser incluída ou excluída, encerrando o processo.

8. Análise do Modelo Final

Modelo após o Stepwise: Y ~ X5 + X7 + X8

Diagnóstico inicial

Após a seleção das variáveis via stepwise o R^2 ajustado ficou em 0.9592, ou seja, aproximadamente 95,92% da variabilidade em é explicada pelas variáveis do modelo.

Resultados dos testes

• Normalidade dos resíduos (Teste de Shapiro) – P-VALOR = 0.5986, sem evidência contra a normalidade dos resíduos ao nível de 5%.
• Heterocedasticidade (Breusch–Pagan e White) – P-VALORES = 0.2052 (BPTEST) e 0.102967 (WHITE_TEST). Não há evidências de heterocedasticidade nos resíduos após a seleção das variáveis via stepwise ao nível de 5%.

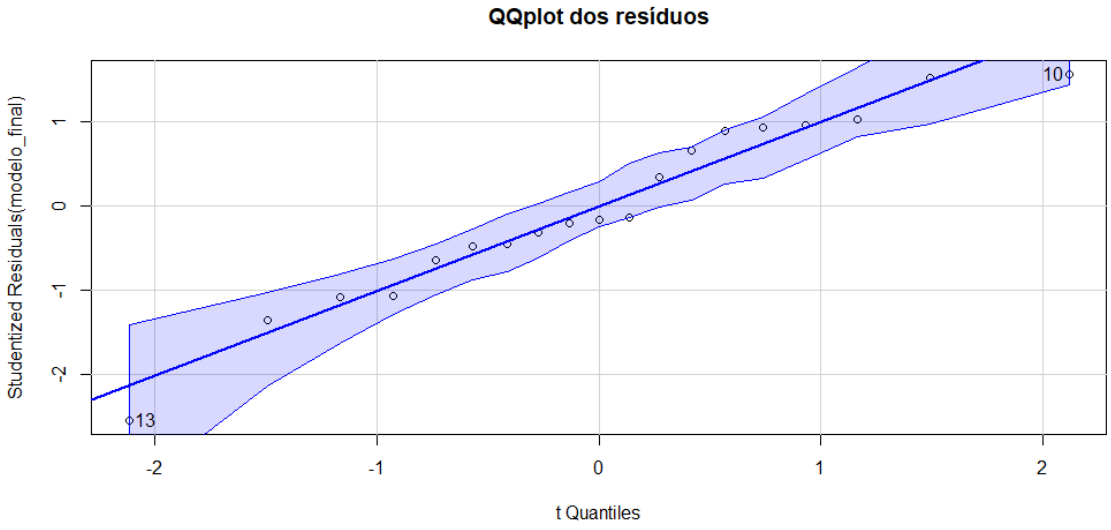

Analise da multicolinearidade

Multicolinearidade (VIF) – As variáveis explicativas presentes no modelo final apresentaram:

X5	X7	X8
1.7437	1.8931	1.6156

VIFs menores que 5, indicando falta de multicolinearidade.

Analise sobre a presença de outliers

Os 8 maiores DFFITs das observações em ordem decrescente foram

19	13	10	12	2	16	17	1
1.5869	1.0000	0.9261	0.6956	0.5805	0.4121	0.4117	0.3888

- Analise dos outliers – As observações 19, 13 e 10 do modelo final apresentaram DFFITs superior ao limite de corte calculado (0.917), indicando presenças de outliers sobretudo na linha 19, no entanto, ao retirarmos essa observação não houve melhoria significativa no modelo, pelo contrário, houve uma pequena piora nos resultados de alguns testes e por isso foi decidido pela sua permanência no modelo final.

9. Considerações Finais

O modelo final selecionado, composto pelas variáveis X5 (peso equivalente de teste), X7 (razão de eixo) e X8 (razão VMW), apresentou um excelente desempenho na explicação da variável resposta Y (consumo), com um R^2 de 0,9**592**, indicando que cerca de 9**5**,**92**% da variabilidade de Y foi explicada pelas variáveis do modelo.

Todos os pressupostos da regressão linear foram verificados e adequadamente atendidos:

- Normalidade dos resíduos foi confirmada pelo teste de Shapiro;

- Ausência de heterocedasticidade foi indicada pelos testes de Breusch-Pagan e White;

- Multicolinearidade não foi detectada;

- Ausência de outliers que afetam negativamente o modelo;

Com base nesses resultados, o modelo final pode ser considerado estatisticamente consistente, bem ajustado e interpretável, sendo adequado para explicar e prever o comportamento da variável de interesse. Porém, apesar de sua boa performance, vale destacar que o modelo está limitado ao conjunto de dados atual, portanto, a inclusão de novos dados poderia contribuir para melhorar sua capacidade preditiva e robustez em aplicações futuras.